

HOJA 3 - EJERCICIO 1

1. Se realiza un estudio sobre la tensión de vapor de agua (ml de Hg.) a distintas temperaturas (°C). Se efectúan 20 medidas y los resultados son los siguientes, denotando por X la variable temperatura y por Y la variable tensión de vapor de agua:

X/Y	0.5-1.5	1.5-2.5	2.5-3.5
0-15	4	2	0
15-25	1	4	2
25-30	0	3	4

X/Y	1	2	3	n_i	N_i	f_i	F_i	d_i	x_i*f_i	x2_i*f_i
7,5	4	2	0	6	6	0,300	0,300	0,400	2,250	16,875
20	1	4	2	7	13	0,350	0,650	0,700	7,000	140,000
27,5	0	3	4	7	20	0,350	1,000	1,400	9,625	264,688
n_j	5	9	6	20	2,050	MEDIA Y			18,875	MEDIA X
N_j	5	14	20		2,056	MEDIANA Y			20,714	MEDIANA X
f_j	0,250	0,450	0,300		2,571	MODA Y			28,333	MODA X
F_j	0,250	0,700	1,000		0,548	s2_y			65,297	s2_x
d_j	5,000	9,000	6,000		0,740	s_y			8,081	s_x
x_j*f_j	0,250	0,900	0,900		0,361	CV_y			0,428	CV_x
x2_j*f_j	0,250	1,800	2,700							

a) Determina la recta de regresión lineal de la variable tensión (Y) en función de la temperatura (X).

X/Y (n_ij)	1	2	3
7,5	4	2	0
20	1	4	2
27,5	0	3	4

n_ij*x_i*y_j	1	2	3	f_ij*x_i*y_j	1	2	3	4,056	COVARIANZA
7,5	30	30	0	7,5	1,500	1,500	0,000	0,678	CORRELACIÓN LINEAL
20	20	160	120	20	1,000	8,000	6,000	a	0,877
27,5	0	165	330	27,5	0,000	8,250	16,500	b	0,062

La recta de regresión ajustada es $\hat{Y}_i = 0.877 + 0.062X_i$ con una correlación lineal de 0.678 (regular, no es débil pero tampoco fuerte)

b) Interpreta los coeficientes ajustados.

Interpretación a: cuando la temperatura es nula, la tensión de vapor vale 0.877
Interpretación b: por cada incremento unitario de la temperatura, la tensión de vapor aumenta 0.062

c) Calcula la SSE estimada.

f_ij*e_ij^2	1	2	3	SSE/N (var. residual)	0,296
7,5	0,024	0,043	0,000	SSE / SST	0,540
20	0,063	0,003	0,077		
27,5	0,000	0,051	0,034		

d) Predice la tensión para una temperatura de 24°C.

Las predicciones son $\hat{Y}_{X=24} = 0.877 + 0.062 * 24 = 2,365$

e) ¿Es fiable la predicción realizada en el apartado anterior?

Calcula la bondad de ajuste del modelo

f) Predice para una temperatura de 35 grados. ¿Es fiable?

La **varianza residual** (media de los residuos al cuadrado) es 0.296. Eso implica que $R^2 = \frac{s_Y^2 - s_r^2}{s_Y^2} = 1 - \frac{s_Y^2}{s_r^2} = r^2 = (0.678)^2$ es el valor 0.460 (solo válido para modelos lineales en los parámetros)

La **predicción** para 24°C no es muy fiable ya que el R2 es bajo. La predicción para **35°C no sería fiable, fuese cual fuese el R2**, ya que el valor de X no está dentro del rango de los datos

Las predicciones son $\hat{Y}_{X=24} = 0.877 + 0.062 * 24 = 2,365$ y $\hat{Y}_{X=35} = 0.877 + 0.062 * 35 = 3,047$

HOJA 3 - EJERCICIO 2

2. Se desea estudiar la relación entre la fuerza (Y en Kg) ejercida sobre cierto tipo de tuberías hasta quebrarlas, y el diámetro de las mismas (X en mm). Observadas ambas variables, hemos obtenida la siguiente muestra de 51 barras:

X/Y	40-50	50-60	60-70	70-80
40-50	5	2	0	0
50-60	9	7	6	4
60-70	1	4	8	1
70-80	0	0	4	0

X/Y	45	55	65	75	n_i	N_i	f_i	F_i	d_i	x_i*f_i	x2_i*f_i
45	5	2	0	0	7	7	0,137	0,137	0,700	6,176	277,941
55	9	7	6	4	26	33	0,510	0,647	2,600	28,039	1542,157
65	1	4	8	1	14	47	0,275	0,922	1,400	17,843	1159,804
75	0	0	4	0	4	51	0,078	1,000	0,400	5,882	441,176
n_j	15	13	18	5	51	57,549	MEDIA Y			57,941	MEDIA X
N_j	15	28	46	51		58,077	MEDIANA Y			57,115	MEDIANA X
f_j	0,294	0,255	0,353	0,098		62,778	MODA Y			56,129	MODA X
F_j	0,294	0,549	0,902	1,000		97,424	s2_y			63,899	s2_x
d_j	1,500	1,300	1,800	0,500		9,870	s_y			7,994	s_x
x_j*f_j	13,235	14,020	22,941	7,353		0,172	CV_y			0,138	CV_x
x2_j*f_j	595,588	771,078	1491,176	551,471							

a) Realiza una predicción lineal de la fuerza que se debería ejercer sobre una tubería de 55mm para quebrarla.

X/Y (n_ij)	45	55	65	75
45	5	2	0	0
55	9	7	6	4
65	1	4	8	1
75	0	0	4	0

										35,640	COVARIANZA
										0,452	CORRELACIÓN LINEAL
										0,204	R2
n_ij * x_i * y_j	45	55	65	75	f_ij * x_i * y_j	45	55	65	75	a	25,232
45	10.125	4950	0	0	45	198,529	97,059	0,000	0,000	b	0,558
55	22.275	21.175	21.450	16.500	55	436,765	415,196	420,588	323,529		
65	2925	14.300	33.800	4875	65	57,353	280,392	662,745	95,588		
75	0	0	19.500	0	75	0,000	0,000	382,353	0,000		

La recta de regresión ajustada es $\hat{Y}_i = 25.232 + 0.558X_i$ con una correlación lineal de 0.452 (relación lineal positiva débil). Para $X = 55$ la predicción será $\hat{Y}_i = 25.232 + 0.558X_i = 55.922$

b) Interpreta los coeficientes ajustados. Calcula la SSE estimada.

Interpretación a: si la tubería fuese de 0mm, la fuerza que se debería ejercer para quebrarla es de 25.232, pero no es fiable ya que queda fuera del rango de datos

Interpretación b: por cada incremento unitario del diámetro, la fuerza requerida para quebrarla aumenta en 0.558

f_ij*e_ij^2	45	55	65	75
45	2,786	0,855	0,000	0,000
55	20,999	0,113	9,724	28,587
65	5,329	3,300	1,937	3,581
75	0,000	0,000	0,334	0,000

SSE/N (var. residual)	77,545
SSE / SST	0,796

c) ¿Qué proporción de la información contenida en Y es explicada por la variable X?

Dado que $R^2 = r^2 = 0.204 = 1 - \frac{SSE}{SST}$ mi modelo de regresión lineal explica solo el 20.4% de la información. Es un modelo muy malo.

HOJA 3 - EJERCICIO 3


3. Las siguientes 5 observaciones conjuntas representan la viscosidad del benceno (Y, en centipoisos) a distintas temperaturas (X, en °C)

X	10	20	30	40	50
Y	0,758	0,652	0,500	0,403	0,390

a) Ajusta un modelo de regresión lineal. Calcula la bondad de ajuste.

						MEDIAS	VARIANZAS	-1,97000	COVARIANZA
X	10	20	30	40	50	30,000	200,000	-0,97085	CORRELACIÓN LINEAL
Y	0,75800	0,65200	0,50000	0,40300	0,39000	0,54060	0,02059	0,94256	R2
XY	7,58000	13,04000	15,00000	16,12000	19,50000	14,24800			

a	0,83610	La recta de regresión ajustada es $\hat{Y}_i = -0.00985 + 0.83610X_i$ con una correlación lineal de -0.971 (relación lineal negativa muy fuerte)
b	-0,00985	



b) Ajusta un modelo hiperbólico. Calcula la bondad de ajuste.

c) Compara los modelos anteriores.

						MEDIAS	VARIANZAS	a	0,32897
X	10	20	30	40	50	30,000	200,000	b	4,63416
Z=1/X	0,10000	0,05000	0,03333	0,02500	0,02000	0,04567	0,00084	0,00390	COVARIANZA (Z,Y)
Y	0,75800	0,65200	0,50000	0,40300	0,39000	0,54060	0,02059	0,93707	CORRELACIÓN LINEAL (Z,Y)
ZY	0,07580	0,03260	0,01667	0,01008	0,00780	0,02859		0,00251	VAR. RESIDUAL
Predicción	0,79239	0,56068	0,48345	0,44483	0,42166			0,87810	R2
e_i^2	0,00118	0,00834	0,00027	0,00175	0,00100	0,00251			

El modelo hiperbólico ajustado es $\hat{Y}_i = 0.32897 + 4.63416 \frac{1}{X_i}$ con un R2 de 0.87810 (ajuste fiable). Para calcular la bondad de ajuste ya no podemos usar la correlación lineal (que sería de Z vs Y, no de X vs Y), sino que debemos calcular la varianza residual (usando la descomposición ANOVA). Aunque es fiable sale mejor el lineal comparando los R2

d) Ajusta un modelo de regresión exponencial.

e) Ajusta un modelo de regresión potencial.

f) Compara la calidad de los cuatro modelos. ¿Con cuál te quedarías?

						MEDIAS	VARIANZAS	-3,62036	COVARIANZA (X, V)
X	10	20	30	40	50	30,000	200,000	-0,14460	COVARIANZA (U, V)
U = ln(X)	2,30259	2,99573	3,40120	3,68888	3,91202	3,26008	0,32310		
Y	0,75800	0,65200	0,50000	0,40300	0,39000	0,54060	0,02059	c (exp)	-0,10662
V = ln(Y)	-0,27707	-0,42771	-0,69315	-0,90882	-0,94161	-0,64967	0,06847	d (exp)	-0,01810
X*V	-2,77072	-8,55421	-20,79442	-36,35275	-47,08043	-23,11050		VAR. RESIDUAL EXP	0,00060
U*V	-0,63798	-1,28131	-2,35753	-3,35252	-3,68359	-2,26259			
Predicción exponencial	0,75004	0,62584	0,52222	0,43575	0,36360			c (pot.)	0,80940
e_i^2	0,00006	0,00068	0,00049	0,00107	0,00070	0,00060		b (pot.)	-0,44756
Predicción potencial	0,80161	0,58781	0,49026	0,43103	0,39006			VAR. RESIDUAL POT	0,00138
e_i^2	0,00190	0,00412	0,00009	0,00079	0,00000	0,00138			

El modelo exponencial ajustado es $\hat{Y}_i = e^{-0.10662 * (e^{0.01810})^{X_i}}$ y el modelo potencial ajustado es $\hat{Y}_i = e^{-0.80940 X_i^{-0.44756}}$. Para comparar necesitamos usar las residuales ya que estos dos modelos no pueden calcularse la bondad de ajuste R2. Las varianzas residuales del hiperbólico, exponencial y potencial son 0.00251, 0.00060 y 0.00138. La del lineal se puede calcular como $R^2 = 1 - \frac{s_r^2}{s_y^2} \rightarrow s_r^2 = s_y^2(1 - R^2) = 0.00118$. Así que el mejor es el exponencial por tener menor varianza residual, y el segundo mejor el lineal muy cerca del exponencial. Usando el principio de parsimonia (la respuesta más simple suele ser la más probable), nos quedaríamos con el lineal por ser más sencillo y ser casi igual de bueno

HOJA 3 - EJERCICIO 4


4. Bajo ciertas condiciones se ha medido el volumen ocupado por determinado gas (Y) al someterlo a distintas presiones (X)

X	0,500	1,000	1,500	2,000	2,500	3,000
Y	1,620	1,000	0,760	0,620	0,520	0,460

- a) Ajusta un modelo de regresión lineal.
- b) Interpreta los coeficientes ajustados, calcula la bondad de ajuste.

							MEDIAS	VARIANZAS	-0,30750	COVARIANZA
X	0,500	1,000	1,500	2,000	2,500	3,000	1,750	0,729	-0,91222	CORRELACIÓN LINEAL
Y	1,620	1,000	0,760	0,620	0,520	0,460	0,83000	0,15583	0,83215	R2
XY	0,81000	1,00000	1,14000	1,24000	1,30000	1,38000	1,14500			

a	1,56800	La recta de regresión ajustada es $\hat{Y}_i = 1.56800 - 0.42171X_i$ con una correlación lineal de 0.83215 (relación lineal positiva fuerte)
b	-0,42171	



Interpretación a: si la presión fuese nula, el volumen ocupado sería de 1.56800, pero no es fiable ya que queda fuera del rango de datos

Interpretación b: por cada incremento unitario de la presión, el volumen ocupado disminuye 0.42171

- c) Ajusta un modelo potencial.
- d) ¿Es mejor el modelo del apartado b) o el del apartado c)?
- e) Ajusta un modelo hiperbólico.
- f) Determina (si se pudiera) cual de los modelos de a), c) y e) mejoran el modelo calculado en 3a).

	HIPERBÓLICO						MEDIAS	VARIANZAS	a	0,26820
X	0,500	1,000	1,500	2,000	2,500	3,000	1,750	0,729	b	0,68792
Z=1/X	2,00000	1,00000	0,66667	0,50000	0,40000	0,33333	0,81667	0,327	0,22517	COVARIANZA (Z,Y)
Y	1,620	1,000	0,760	0,620	0,520	0,460	0,83000	0,156	0,99699	CORRELACIÓN LINEAL (Z,Y)
ZY	3,24000	1,00000	0,50667	0,31000	0,20800	0,15333	0,90300		0,00094	VAR. RESIDUAL
Predicción	1,64404	0,95612	0,72681	0,61216	0,54337	0,49750			0,99399	R2
e_i^2	0,00058	0,00193	0,00110	0,00006	0,00055	0,00141	0,00094			

El modelo hiperbólico ajustado es $\hat{Y}_i = 0.26820 + 0.68792 \frac{1}{X_i}$ con un R2 de 0.99399 (ajuste muy fiable, casi perfecto). Para calcular la bondad de ajuste ya no podemos usar la correlación lineal (que sería de Z vs Y, no de X vs Y), sino que debemos calcular la varianza residual (usando la descomposición ANOVA). Es un mejor ajuste que la regresión lineal

	EXPONENCIAL Y POTENCIAL						MEDIAS	VARIANZAS	-0,35251	COVARIANZA (X, V)
X	0,500	1,000	1,500	2,000	2,500	3,000	1,750	0,729	-0,25722	COVARIANZA (U, V)
U = ln(X)	-0,69315	0,00000	0,40547	0,69315	0,91629	1,09861	0,40339	0,366		
Y	1,620	1,000	0,760	0,620	0,520	0,460	0,83000	0,156	c (exp)	0,56260
V = ln(Y)	0,48243	0,00000	-0,27444	-0,47804	-0,65393	-0,77653	-0,28342	0,181	d (exp)	-0,48344
X*V	0,24121	0,00000	-0,41166	-0,95607	-1,63482	-2,32959	-0,84849		VAR. RESIDUAL EXP	0,01298
U*V	-0,33439	0,00000	-0,11127	-0,33135	-0,59919	-0,85310	-0,37155			
Predicción exponencial	1,37834	1,08238	0,84997	0,66746	0,52414	0,41160			c (pot.)	0,00015
e_i^2	0,05840	0,00679	0,00809	0,00225	0,00002	0,00234	0,01298		b (pot.)	-0,70296
Predicción potencial	1,62809	1,00015	0,75211	0,61440	0,52521	0,46203			VAR. RESIDUAL POT	0,00003
e_i^2	0,00007	0,00000	0,00006	0,00003	0,00003	0,00000	0,00003			

El modelo exponencial ajustado es $\hat{Y}_i = e^{-0.56260} * (e^{-0.48344})^{X_i}$ y el modelo potencial ajustado es $\hat{Y}_i = e^{-0.00015} X_i^{-0.70296}$. Para comparar necesitamos usar las residuales ya que estos dos modelos no pueden calcularse la bondad de ajuste R2. La del lineal se puede calcular como $R^2 = 1 - \frac{s_r^2}{s_y^2} \rightarrow s_r^2 = s_y^2(1 - R^2) = 0.02616$. Así que el mejor es el potencial que es casi perfecto, por tener una varianza residual muy cercana a cero, superando por mucho al resto de modelos.

Respecto a la comparación 3a), al ser otra tabla, no podemos comparar varianzas residuales, así que sólo podremos comparar el 3a) vs 4a) y 4e), donde podemos calcular la bondad de ajuste: el mejor es el hiperbólico del apartado 4e) por tener una bondad de ajuste más cercana a uno.

HOJA 3 - EJERCICIO 5

5. Dada una distribución bidimensional (X, Y) cuyas rectas de regresión son $x+4y=1$ y $x+5y=2$, calcula el coeficiente de correlación lineal. Interpreta su valor.

Vamos a asumir de inicio que la primera recta es Y|X y la segunda X|Y de forma que $y = \frac{1-x}{4}$ y $x = 2-5y$.

Sabemos que los coeficientes de las pendientes deben cumplir $b = \frac{s_{xy}}{s_x^2} = -\frac{1}{4}$ y $b' = \frac{s_{xy}}{s_y^2} = -5$. Además sabemos

que $R^2 = r^2 = \frac{s_{xy}^2}{s_x^2 s_y^2}$ por lo que sería $R^2 = r^2 = \frac{s_{xy}^2}{s_x^2 s_y^2} = b * b' = \frac{5}{4} \implies$ ¡NO PUEDE SER MAYOR QUE 1!

Vamos a asumir ahora lo contrario: la primera recta es X|Y y la segunda Y|X de forma que $x = 1-4y$ y $y = \frac{2-x}{5}$. Sabemos que los coeficientes de las pendientes deben cumplir $b = \frac{s_{xy}}{s_x^2} = -4$ y $b' = \frac{s_{xy}}{s_y^2} = -\frac{1}{5}$. Además

sabemos que $R^2 = r^2 = \frac{s_{xy}^2}{s_x^2 s_y^2}$ por lo que sería $R^2 = r^2 = \frac{s_{xy}^2}{s_x^2 s_y^2} = b * b' = \frac{4}{5} \implies$ Esta es la opción correcta de rectas.

HOJA 3 - EJERCICIO 6

6. Dada una distribución bidimensional (X, Y), la recta de regresión ajustada (estimada) de Y|X es $y=3x+5$. Determina:

- a) La recta de regresión de X|Y sabiendo que $r = 1$.
- b) La recta de regresión de X|Y sabiendo que $r = 0.9$ y que $\bar{x} = 1$
- c) ¿Sería posible que en este modelo r fuera negativo? Razona la respuesta.

Si $r = 1$ implica que $R^2 = r^2 = 1 = b * b'$. Como $b = 3$, entonces la pendiente de la otra recta debe ser $b' = \frac{1}{3}$, es decir, la recta X|Y será $x = a' + b'y = a' + \frac{1}{3}y$. Despejando en la otra ecuación tenemos $x = \frac{-5 + y}{3}$.

Si $r = 0.9$ implica que $R^2 = r^2 = 0.81 = b * b'$. Como $b = 3$, entonces la pendiente de la otra recta debe ser $b' = \frac{27}{100} = 0.27$, es decir, la recta X|Y será $x = a' + b'y = a' + 0.27y$. No podemos despejar como antes ya que no tienen correlación 1.

Si sabemos que $\bar{x} = 1$, por lo que tomando medias tenemos que $\bar{y} = 3\bar{x} + 5 = 8$. Tomando medias en la segunda recta, tenemos que $\bar{x} = a' + 0.27\bar{y}$. Esto resulta en $a' = -1.16$

Dado que $r = \frac{s_{xy}}{s_x s_y}$, el signo de la correlación viene dado por el de la covarianza. A su vez $b = \frac{s_{xy}}{s_x^2}$ por lo que su signo será el mismo que el de r . Al tener $b = 3$, es imposible que $r < 0$.

HOJA 3 - EJERCICIO 7

7. Los siguientes datos corresponden a la cantidad de una sustancia (Y) que permanece pasado un periodo de tiempo (X).


X	1	5	10	25	50	100
Y	96	75	63	30	9	2

- a) Calcula la media de cada variable. ¿Cuál de las dos es más dispersa respecto a la media?
- b) Calcula la covarianza y la correlación lineal e interpreta con detalle.
- c) Realiza un ajuste lineal Y|X. Calcula la bondad de ajuste (comenta el resultado obtenido), interpreta los coeficientes ajustados y calcula la SSE estimada.

							MEDIAS	VARIANZAS	CV	-1042,19444	COVARIANZA
X	1	5	10	25	50	100	31,833	1195,139	1,086	-0,87081	CORRELACIÓN LINEAL
Y	96	75	63	30	9	2	45,83333	1198,47222	0,755	0,75832	R2
XY	96,00	375,00	630,00	750,00	450,00	200,00	416,83333			1737,89759	SSE

a	73,59289	Interpretación a: si no ha pasado tiempo (X nula), la cantidad de la sustancia es 73.59289, pero no es fiable ya que queda fuera del rango de datos
b	-0,87203	Interpretación b: por cada paso unitario temporal (por cada segundo que pase), la cantidad disminuye -0.87203.

Es más dispersa la X ya que tiene un CV ligeramente mayor. Respecto a la correlación, hay un correlación negativa fuerte, el ajuste lineal da una bondad de ajuste de 0.75832 lo que hace que sea un ajuste más o menos fiable. La SSE es $SSE = n * s_e^2 = n * s_y^2(1 - R^2)$



- d) Realiza un ajuste hiperbólico y determina si es mejor que el anterior ajuste lineal.
- e) Realiza un ajuste exponencial y un ajuste potencial y determina con cual de los cuatro modelos te quedarías.

HIPERBÓLICO							MEDIAS	VARIANZAS	a	28,566
X	1,000	5,000	10,000	25,000	50,000	100,000	31,833	1195,139	b	75,625
Z=1/X	1,000	0,200	0,100	0,040	0,020	0,010	0,22833	0,123	9,318	COVARIANZA (Z,Y)
Y	96,000	75,000	63,000	30,000	9,000	2,000	45,83333	1198,472	0,767	CORRELACIÓN LINEAL (Z,Y)
ZY	96,000	15,000	6,300	1,200	0,180	0,020	19,78333		493,794	VAR. RESIDUAL
Predicción	104,191	43,691	36,128	31,591	30,078	29,322			0,588	R2
e_i^2	67,087	980,277	722,098	2,530	444,287	746,484	493,79388			

El modelo hiperbólico ajustado es $\hat{Y}_i = 28.566 + 75.625 \frac{1}{X_i}$ con un R2 de 0.588 (ajuste poco fiable). Para calcular la bondad de ajuste ya no podemos usar la correlación lineal (que sería de Z vs Y, no de X vs Y), sino que debemos calcular la varianza residual (usando la descomposición ANOVA). Es mejor ajuste la regresión lineal

EXPONENCIAL Y POTENCIAL							MEDIAS	VARIANZAS	-47,187	COVARIANZA (X, V)
X	1,000	5,000	10,000	25,000	50,000	100,000	31,833	1195,139	-1,859	COVARIANZA (U, V)
U = ln(X)	0,000	1,609	2,303	3,219	3,912	4,605	2,608	2,326		
Y	96,000	75,000	63,000	30,000	9,000	2,000	45,833	1198,472	c (exp)	4,476
V = ln(Y)	4,564	4,317	4,143	3,401	2,197	0,693	3,219	1,888	d (exp)	-0,039
X*V	4,564	21,587	41,431	85,030	109,861	69,315	55,298		VAR. RESIDUAL EXP	28,742
U*V	0,000	6,949	9,540	10,948	8,596	3,192	6,537			
Predicción exponencial	84,504	72,158	59,231	32,760	12,209	1,696			c (pot.)	5,304
e_i^2	132,168	8,074	14,202	7,620	10,297	0,093	28,742		b (pot.)	-0,799
Predicción potencial	201,132	55,566	31,930	15,351	8,821	5,069			VAR. RESIDUAL POT	2103,307
e_i^2	11.052,769	377,688	965,341	214,596	0,032	9,418	2103,307			

Para comparar necesitamos usar las residuales ya que estos dos modelos no pueden calcularse la bondad de ajuste R2. Así que el mejor es el exponencial por tener la varianza residual más pequeña